Σχεδιασμός και υλοποίηση μηχανισμών pipe και fork σε unikernels

Μάινας Χαράλαμπος

Επιβλέπων: Γεώργιος Γκούμας

Εργαστήριο Υπολογιστικών Συστημάτων
Σχολή Ηλεκτρολόγων Μηχανικών και Μηχανικών Υπολογιστών
Εθνικό Μετσόβιο Πολυτεχνείο
WWW: `http://cslab.ece.ntua.gr/research/`

Μάρτιος 2019

Επισκόπηση

Εισαγωγή

Unikernels

Εξειδικευμένες εικόνες μηχανές, με ένα μοναδικό χώρο διευθύνσεων, τα οποία κατασκευάζονται χρησιμοποιώντας library operating systems

Αναλύοντας τον ορισμό

- Εξειδικευμένες: κάθε unikernel περιέχει μία και μόνο εφαρμογή και έχει χτιστεί με σκοπό την υποστήριξη μόνο αυτής.
- Μοναδικός χώρος διευθύνσεων: δεν υπάρχει διαχωρισμός kernel space και user space.
- library operating systems: λειτουργικά συστήματα που παρέχουν τις υπηρεσίες που υποστηρίζουν (π.χ. networking) σε μορφή βιβλιοθηκών, οι οποίες μπορούν να χρησιμοποιηθούν (link) από τις εφαμρογές.

Typical OS vs unikernel

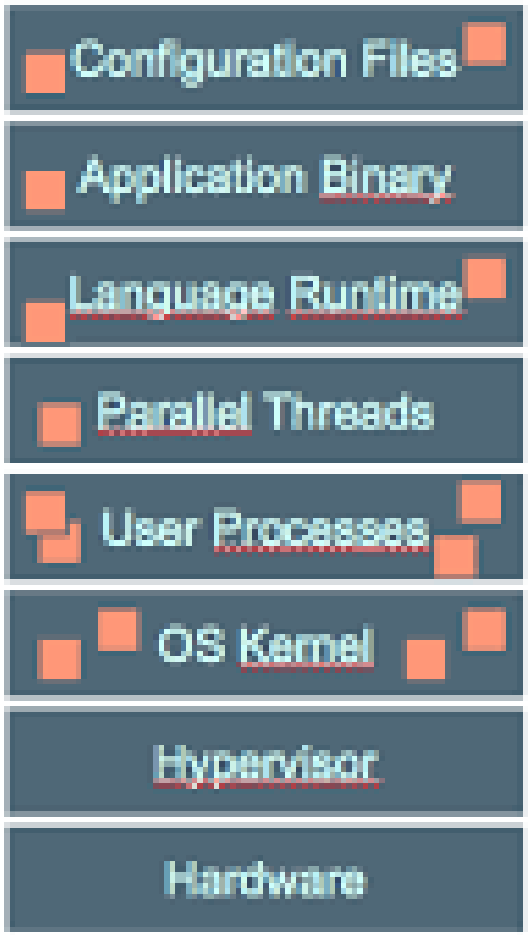

Typical application running above an OS

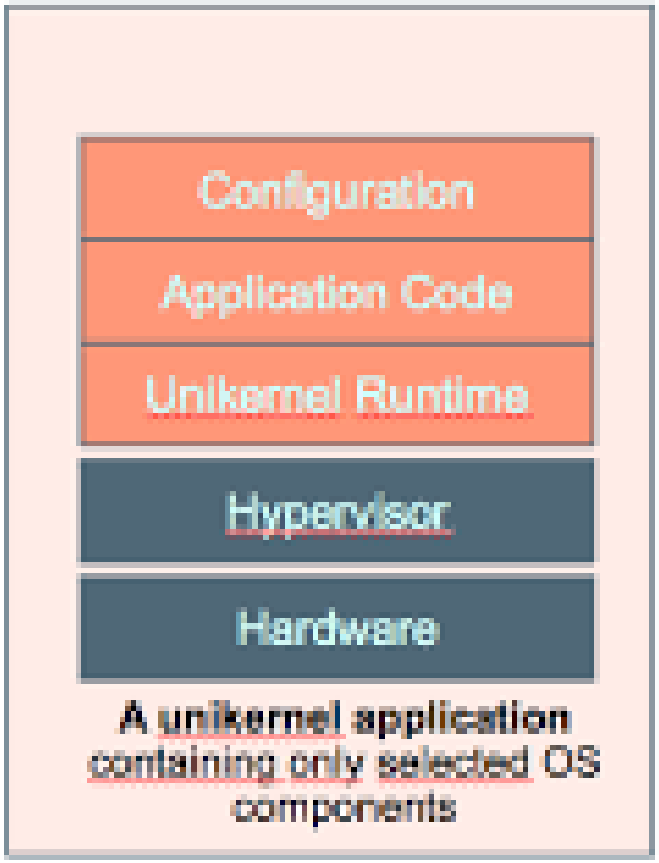

A unikernel application containing only selected OS components

Χαρακτηριστικά των unikernels

Πλεονεκτήματα

- Γρήγοροι χρόνοι εκκίνησης
- Μικρό memory footprint
- Περισσότερη ασφάλεια

Μειονεκτήματα

- Οι εφαρμογές χρειάζονται porting
- Πολλές βιβλιοθήκες μπορεί να μην υποστηρίζονται
- Πολλά components των OSes μπορεί να μην υποστηρίζονται (single process)

National Technical University of Athens
CSLab

Επισκόπηση

National Technical University of Athens
CSLab

Unikernel frameworks

Rumprun

- Είναι βασισμένο στο NetBSD και συγκεκριμένα στα rump kernels
- POSIX friendly
- Υποστήριξη για threads, filesystem
- Υποστηρίζει πολλές γλώσσες
- Πολλές εφαρμογές έτοιμες να εκτελεστούν σε αυτό

Unikernel frameworks

OSv

- Είναι φτιαγμένο από την αρχή, με στόχο να εκτελείται στο cloud
- POSIX compatible
- Υποστήριξη για threads, filesystem.
- Υποστηρίζει πολλές γλώσσες
- Πολλές εφαρμογές έτοιμες να εκτελεστούν σε αυτό
- Από τα πιο ενεργά projects

National Technical University of Athens
CSLab

Unikernel frameworks

IncludeOS

- Είναι φτιαγμένο από την αρχή
- Μερικώς POSIX compatible
- single threaded
- Ταχύτατα αναπτυσσόμενο project
- Μόνο εφαμρογές σε C++ μπορούν να εκτελεστούν σε αυτό

Unikernel frameworks

MirageOS

- Είναι φτιαγμένο από την αρχή και είναι γραμμένο σε OCaml
- Μόνο εφαρμογές σε OCaml μπορούν να εκτελεστούν σε αυτό
- Από τα πιο παλιά unikernel frameworks

Unikernel frameworks

MirageOS

- Είναι φτιαγμένο από την αρχή και είναι γραμμένο σε OCaml
- Μόνο εφαρμογές σε OCaml μπορούν να εκτελεστούν σε αυτό
- Από τα πιο παλιά unikernel frameworks

Πολλά ακόμα

- ClickOS
- LKL
- Mini-OS, Unikraft
- HalVM, LING

Rumprun

Anykernels

Codebase (πυρήνα) όπου οι οδηγοί μπορούν να εξαχθούν και να ενσωματωθούν σε οποιοδήποτε μοντέλο ΛΣ

Rump kernels

παρέχουν drivers του NetBSD ως φορητά εξαρτήματα με τα οποία μπορούμε να εκτελέσουμε εφαρμογές χωρίς να ναι απαραίτητη η ύπαρξη ΛΣ

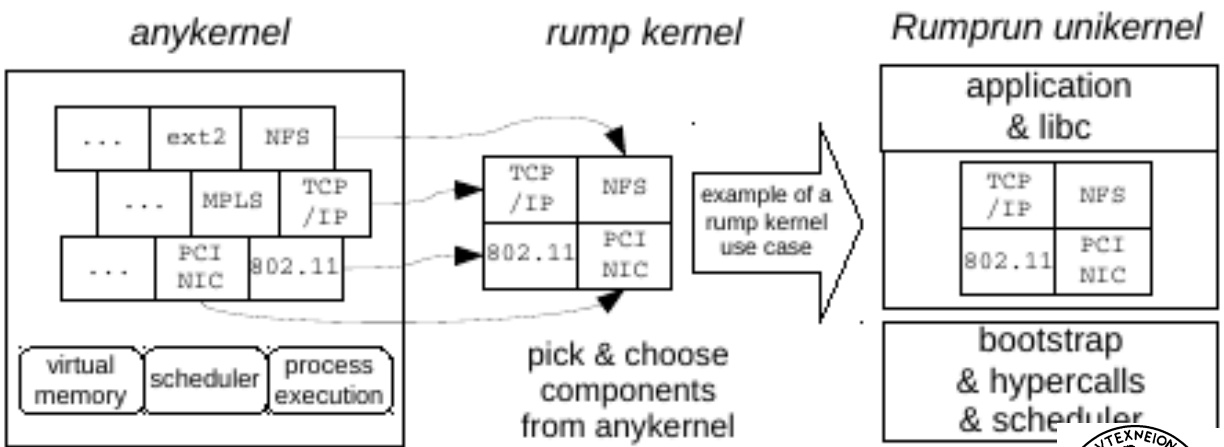

Rumprun stack

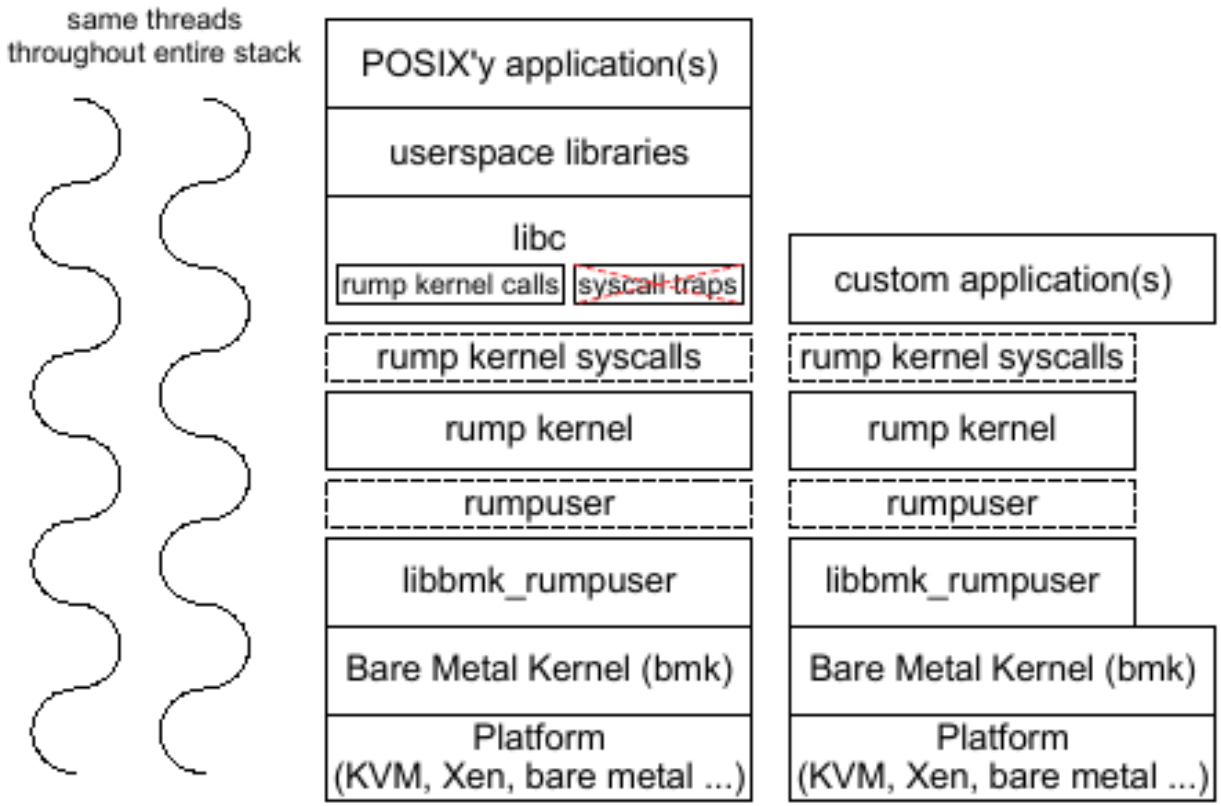

Επισκόπηση

Βασική ιδέα

Κοινό χαρακτηριστικό

- Βασικό κοινό χαρακτηριστικό όλων των unikernels, είναι ότι είναι single process
- Συνεπώς δεν υποστηρίζεται η κλήση fork, σε κανένα unikernel

Ιδέα

- Προσπαθούμε να κάνουμε τα unikernels όσο πιο πολύ POSIX friendly γίνεται
- Θέλουμε να κρατήσουμε τα βασικά χαρακτηριστικά των unikernels
- Αντιλαμβανόμαστε τα unikernels ως διεργασίες και το hypervisor ως λειτουργικό συτημα
- Συνεπώς μία κλήση fork, θα οδηγούσε στη δημιουργία μίας νέας διεργασίας unikernel, αντί για μία διεργασία μέσα στο υπάρχον unikernel.

Επισκόπηση

Γενική εικόνα

Pipe system call

int pipe(int fildes[2]);

Pipe semantics:

- Αν το pipe είναι άδειο, η κλήση ανάγνωσης μπλοκάρει μέχρι να προκύψουν δεδομένα
- Αν το pipe είναι γεμάτο, η κλήση εγγραφής μπλοκάρει μέχρι να ρλρυθερωθεί χώρος
- Αν δεν υπάρχουν ανοιχτά άκρα εγγραφής, τότε εανάγνωση στο pipe επιστρέφει 0, end of file
- Αν δεν υπάρχουν ανοιχτά άκρα ανάγνωσης, τότε εγγραφή στο pipe επιστρέφει το error EPIPE

Γενική εικόνα

Pipe σε unikernels

Η κλήση συστήματος pipe χρησιμοποιείται από τα unikernels, όπως θα χρησιμοποιούταν από τις διεργασίες σε ένα συμβατικό ΛΣ>

Τρία στάδια υλοποίησης

1. function call (με χρήση TCP/IP sockets)
2. system call (με χρήση UDP sockets)
3. system call (με χρήση κοινής μνήμης μεταξύ εικονικών μηχανών)

Επισκόπηση

National Technical University of Athens
CSLab

Πρώτο στάδιο υλοποίησης

function call

- Προσθέτουμε στον κώδικα της εφαρμογής, το function call pipe
- Καλώντας τη συνάρτηση δημιουργούνται δύο sockets, ένα για την αποστολή και ένα για τη λήψη δεδομένων.
- Τα δύο αυτά sockets επιστρέφονται και μπορούν να χρησιμοποιηθούν αντίστοιχα
- Η διεύθυνση του παραλήπτη, ορίζεται στον κώδικα της εφαρμογής
- Δεν υλοποιήθηκαν όλα τα semantics του pipe

Επισκόπηση

Δεύτερο στάδιο υλοποίησης

system call

- Χρήση UDP sockets, αντί για TCP
- Δημιουργία system call για τον πυρήνα του NetBSD
- Δημιουργία δύο sockets, ένα για αποστολή και ένα για λήψη δεδομένων.
- Επιστρέφονται δύο file descriptors, ένα για εγγραφή και ένα για ανάγνωση.
- Η διεύθυνση του παραλήπτη, ορίζεται μέσω μίας κλήσης ioctl στο άκρο εγγραφής του pipe.
- Δεν υλοποιήθηκαν όλα τα semantics του pipe

Επισκόπηση

Τρίτο στάδιο υλοποίησης

system call

- Χρήση κοινής μνήμης μεταξύ των εικονικών μηχανών (ivshmem - nahanni)
- Επιστρέφονται δύο file descriptors, ένα για εγγραφή και ένα για ανάγνωση.
- Μόνο για unikernels που μοιράζονται τον ίδιο host
- Υλοποιήθηκαν όλα τα semantics του pipe

National Technical University of Athens
CSLab

Τρίτο στάδιο υλοποίησης

ivshmem

- Για την κοινή μνήμη χρησιμοποιήθηκε ο μηχανισμός ivshmem - nahanni
- Επιτρέπει την κοινή μνήμη μεταξύ δύο εικωνικών μηχανών σε QEMU
- Πρέπει να υλοποιηθεί ένας PCI driver για τη χρήση του

Υλοποίηση

- PCI driver για το NetBSD και το rumprun
- Pipe system call που χρησιμοποιεί την κοινή μνήμη

Τρίτο στάδιο υλοποίησης

Υλοποίηση

- PCI driver για το NetBSD και το rumprun
- Pipe system call που χρησιμοποιεί την κοινή μνήμη

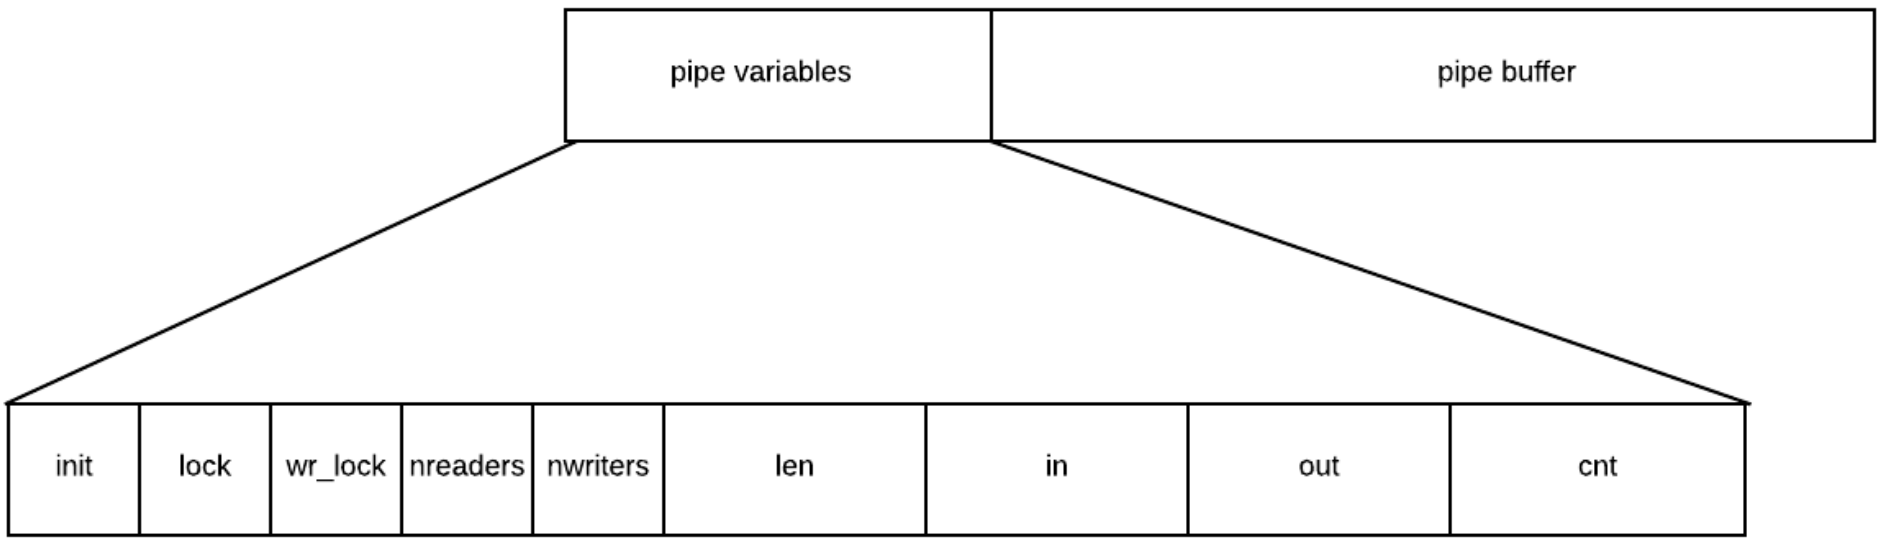

Τρίτο στάδιο υλοποίησης

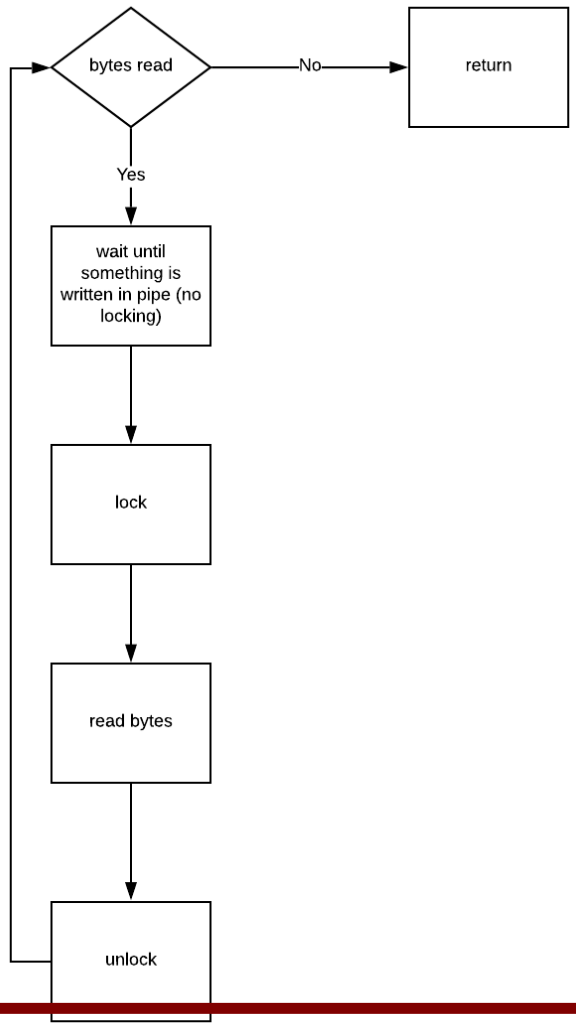

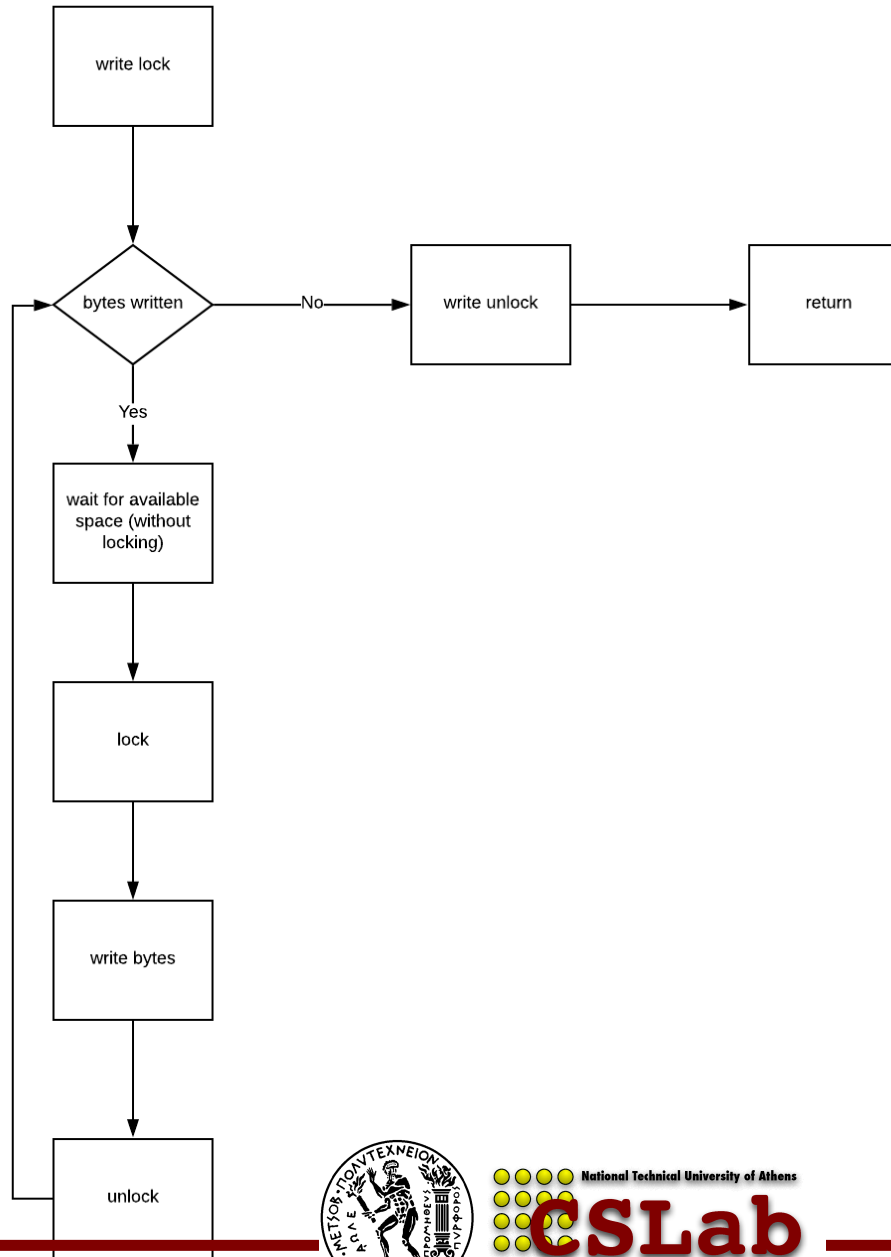

Επισκόπηση

National Technical University of Athens
CSLab

Γενική εικόνα

fork system call

- Δημιουργία νέας διεργασίας
- Η νέα διεργασία είναι ίδια με τη διεργασία γονέα
- Διαχωρισμός των δύο διεργασιών με τιμή επιστροφής από την κλήση συστήματος
- Τα ανοιχτά file descriptors της διεργασίας γονέα, διατηρούνται και στη διεργασία παιδί

Γενική εικόνα

fork system call

- Δημιουργία νέας διεργασίας
- Η νέα διεργασία είναι ίδια με τη διεργασία γονέα
- Διαχωρισμός των δύο διεργασιών με τιμή επιστροφής από την κλήση συστήματος
- Τα ανοιχτά file descriptors της διεργασίας γονέα, διατηρούνται και στη διεργασία παιδί

Στόχος

Η μεταφορά της ίδιας λειτουργίας σε επίπεδο εικονικών μηχανών

Γενική εικόνα

Υλοποίηση

- Χρήση του μηχανισμού migration, που παρέχει το QEMU, με μικρές αλλαγές
- hypercalls από το fork system call του rumprun

Βήματα

- Ενημέρωση των κοινών μεταβλητών του pipe (αν υπάρχει pipe)
- Εκκίνηση διαδικασίας migration
- Αναμονή για migration
- Εκκίνηση νέας εικονικής μηχανής με βάση το migration file

Γενική εικόνα

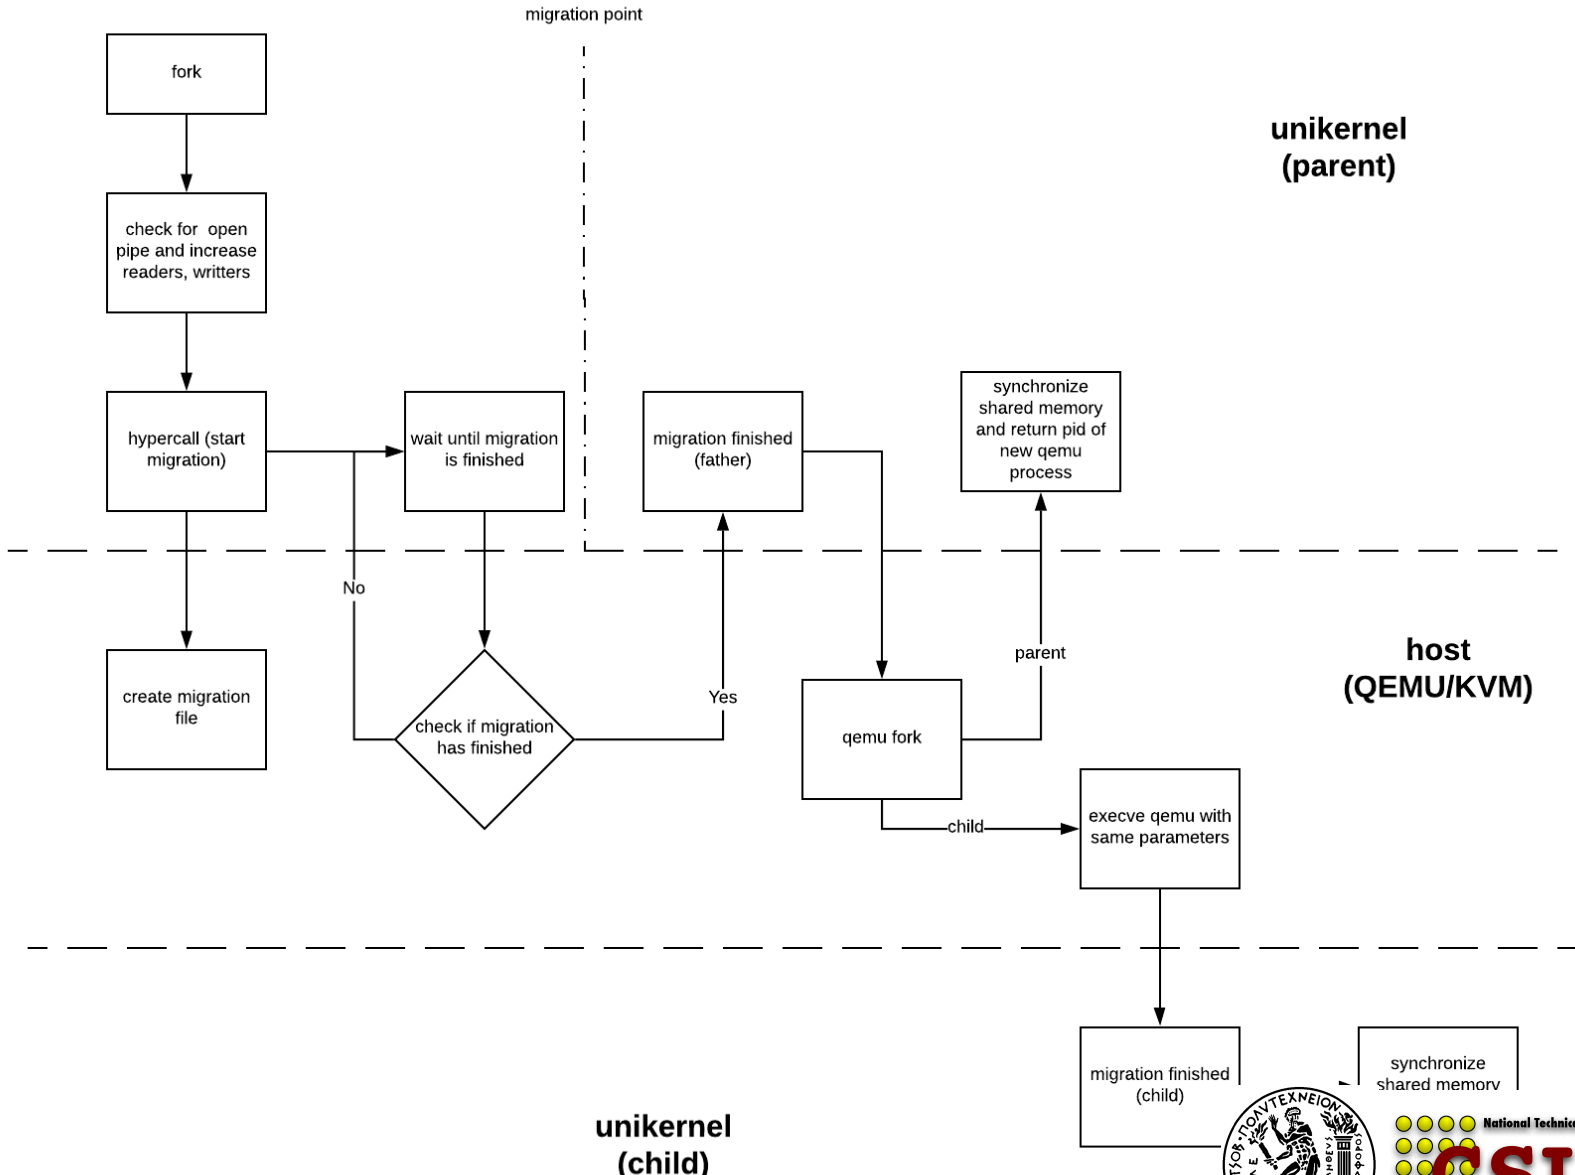

Γενική εικόνα

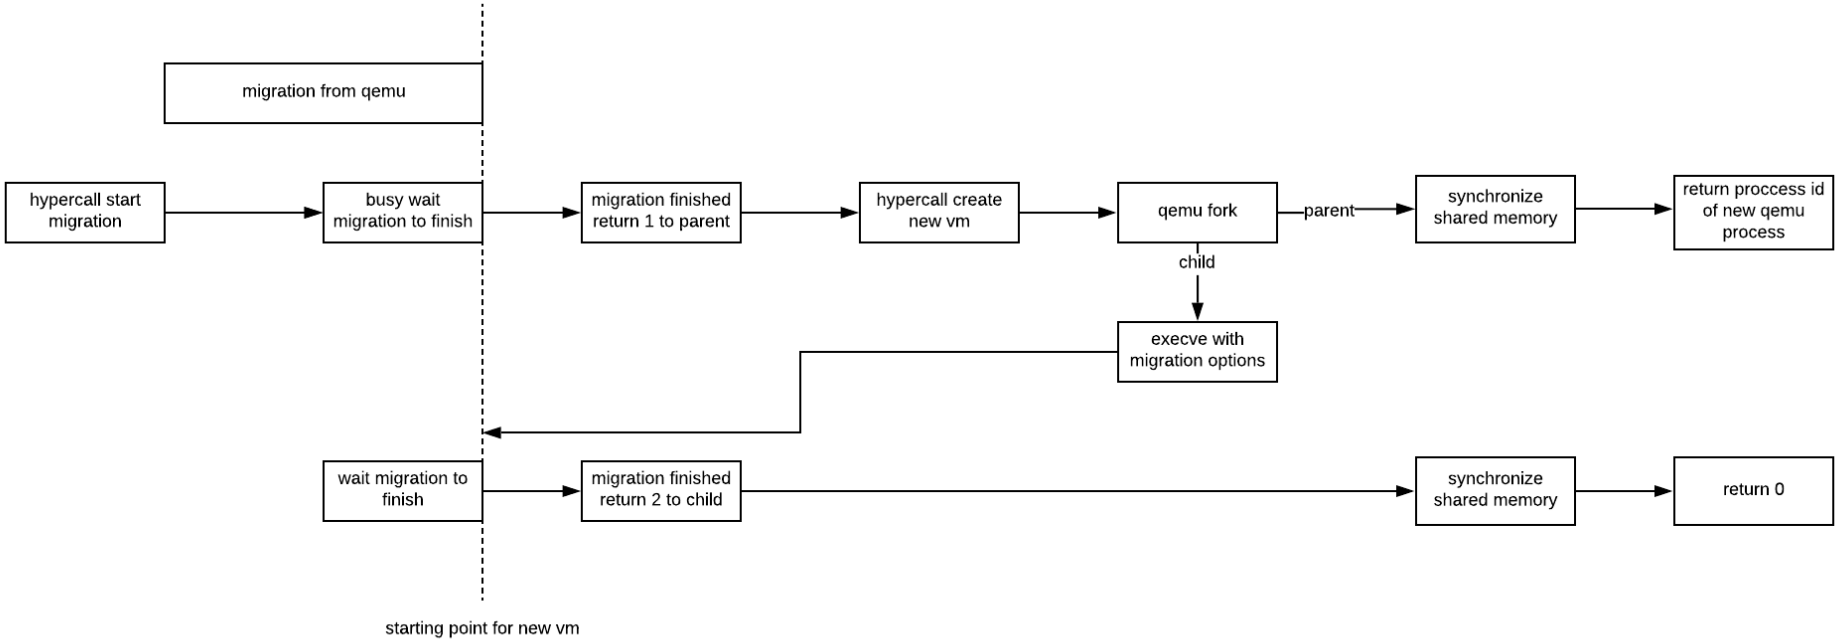

Επισκόπηση

National Technical University of Athens
CSLab

Ενημέρωση κοινών μεταβλητών στο pipe

- Αν υπάρχει pipe θα πρέπει να ενημρωθούν οι κοινές μεταβλητές
- Έλεγχος ύπαρξης pipe, μέσω των ανοιχτών file descriptors της εφαρμογής
- Αύξηση των μετρητών ανοιχτών άκρων
- Χάρις το migration, η εικονική μηχανή παιδί θα έχει πρόσβαση στην κοινή μνήμη

Εκκίνηση δημιουργίας migration file

Από τη μεριά του rumprun

Hypercall για την εκκίνηση δημιουργίας migration file

Από τη μεριά του QEMU

- Χρήση του μηχανισμού migration του QEMU
- Δημιουργία ενος thread, που αναλαμβάνει αυτή την εργασία
- Μικρές αλλαγές στον κώδικα του migration, ώστε να μη σταματήσει η λειτουργία της εικονικής μηχανής γονέας
- Καθόλη τη διάρκεια του migration η εικονική μηχανή θα πρέπει να εκτελείται

Αναμονή για την περάτωση του migration

Από τη μεριά του rumprun

- Busy wait με συνεχή hypercalls
- Είναι το σημείο που θα εκκινήσει τη λειτουργεία του το unikernel παιδί.

Από τη μεριά του QEMU

- Για κάθε hypercall ελέγχεται αν το migration thread εκτελείται ακόμα
- Διατήρηση counter, για τα πόσα hypercalls γίνονται

Αναμονή για την περάτωση του migration

Hypercalls counter

- Με αυτόν διακρίνουμε αν πρόκειται για το παιδί ή το γονέα
- Κάθε εικονική μηχανή στο QEMU είναι μία ξεχωριστή διεργασία, άρα διαφορετικοί counters για κάθε vm
- Migration είναι χρονοβόρα διαδικασία, ο γονέας θα κάνει αρκετά hypercalls
- Όταν θα εκκινήσει το παιδί το migration θα έχει ολοκληρωθεί, άρα ακριβώς ένα hypercall

Αναμονή για την περάτωση του migration

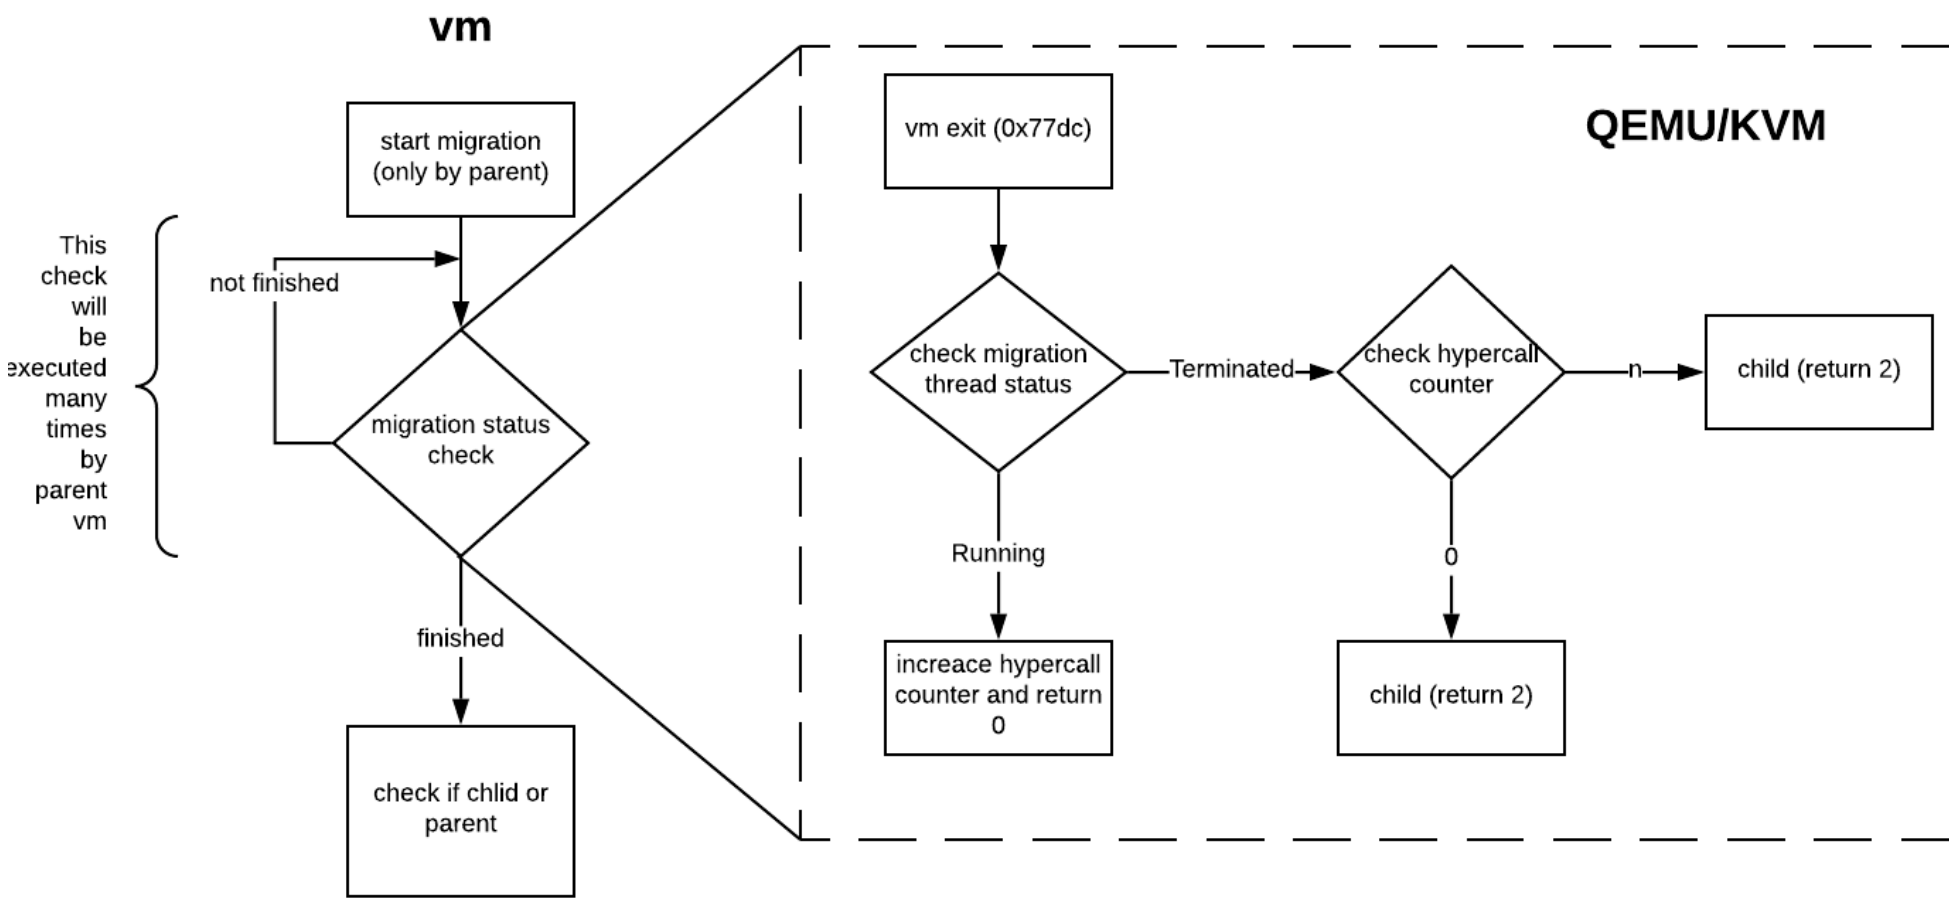

Δημιουργία νέας εικονικής μηχανής

Από τη μεριά του rumprun

Hypercall για την εκκίνηση νέας εικονικής μηχανής

Από τη μεριά του QEMU

- fork
- Επιστροφή στον γονέα το process id της νέας διεργασίας
- Εκκίνηση νέας εικονικής μηχανής με βάση το migration file

Συγχρονισμός εικονικής μνήμης

- Μόνο στην περίπτωση που χρησιμοποιείται pipe
- Παρατηρήθηκε ότι αν το παιδί δε γράψει κάτι στην κοινή μνήμη, τότε το παιδί δεν μπορεί να διαβάσει τα δεδομένα που γράφει ο γονιός
- Busy wait από το γονιό, να αλλάξει μία τιμή το παιδί
- Το παιδί, απλά γράφει μία προκαθορισμένη τιμή σε μία συγκεκριμένη θέση μνήμης

Επισκόπηση

National Technical University of Athens
CSLab

Μετρήσεις

Σύγκριση fork

- Σύγκριση fork σε linux πυρήνα και του fork που δημιουργήσαμε
- Σε ίδια έκδοση QEMU (2.11.2)
- Linux 4.9.0-7-amd64 #1 SMP Debian 4.9.110-3+deb9u2
- Linux: 0.541ms, Unikernel: 137,423ms
- Λογική η διαφορά, αλλά γιατί τόσο μεγάλη?

National Technical University of Athens
CSLab

Time for each step in fork

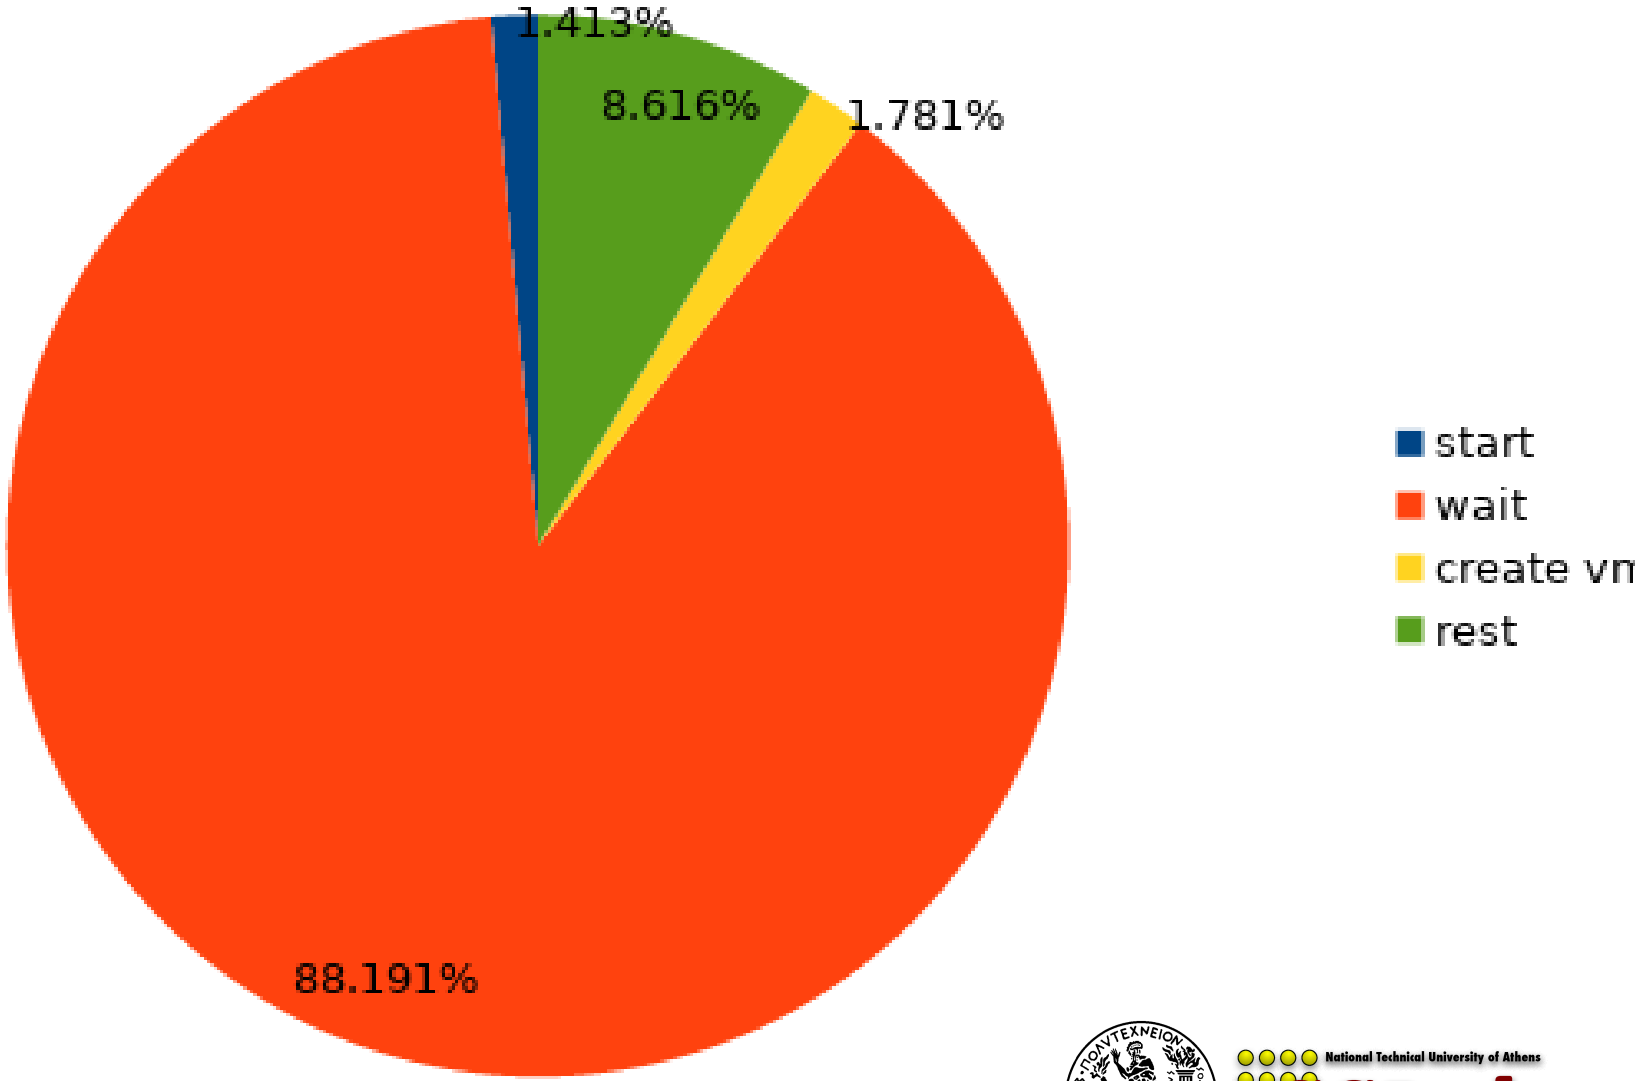

Σύνοψη

Τα unikernels:

- αποτελούν μία αρκετά ενδιαφέρουσα τεχνολογία
- έχουν διαφορετικούς στόχους ανάλογα με το project
- (μερικά frameworks) προσπαθούν να είναι POSIX compatible
- είναι από μόνα τους single process

Αντιμετόπιση των unikernels ως διεργασίες

- Μηχανισμός pipe για unikernels σε ίδιο και διαφορετικό host
- Μηχανσιμός fork για unikernels σε ίδιο host

National Technical University of Athens
CSLab

Μελλοντικές Επεκτάσεις

- Χρήση σημάτων, ώστε να μη βασίζεται ο μηχανισμός pipe τόσο στην κοινή μνήμη
- Επέκταση των inter-unikernel μηχανισμών επικοινωνίας (signaling, message queues)
- Βελτίωση μηχανισμού fork, δημιουργώντας καλύτερο migration μηχανισμό
- Επέκταση του μηχανισμού και σε άλλες πλατφόρμες.

Ευχαριστώ!

Ερωτήσεις;

Backup